

CONCETTI FONDAMENTALI DI TEORIA

Ricerca operativa

Modelli nella ricerca operativa

Problema di ottimizzazione: consiste nel determinare se esistono uno o più punti di massimo o di minimo.

Regione ammissibile: la regione ammissibile è data dal soddisfacimento dei vari vincoli; geometricamente corrisponde ad un poliedro convesso.

In un problema di programmazione lineare sono valide quattro assunzioni implicite:

1. **Proporzionalità:** il contributo di ogni variabile decisionale, al valore della funzione obiettivo, è proporzionale rispetto al valore assunto dalla variabile stessa.
2. **Additività:** ogni funzione è la somma dei contributi delle variabili decisionali
3. **Continuità:** qualunque valore delle variabili decisionali in $\mathbb{R}^n$ è accettabile.
4. **Certezza:** il valore assegnato ad ogni parametro è assunto essere noto e costante.

Metodo del simplesso:

Vertici adiacenti: Se ci sono n variabili decisionali, due vertici sono adiacenti se condividono $n - 1$ frontiere di vincoli.

Spigolo: Segmento che giace all'intersezione delle frontiere di vincoli.

Test di ottimalità: Se una soluzione vertice non ammette soluzioni vertici a lei adiacenti con valore della funzione obiettivo $\mathbb{Z}$ migliore, allora la soluzione in questione è ottimale.

Il metodo del simplesso valuta e compara i tassi di miglioramento: un tasso positivo significa che il vertice adiacente è una soluzione migliore della soluzione corrente, viceversa è peggiore. Il test consiste nel verificare se esiste uno spigolo con tasso positivo di miglioramento: se non è soddisfatta la ricerca, allora la soluzione corrente è quella ottimale.

Variabili slack: è necessario tradurre i vincoli funzionali di disequaglianza in vincoli funzionali di eguaglianza, introducendo una slack che serve a colmare la differenza che al membro sinistro mancherebbe nel verificare la disequaglianza come uguaglianza. Le variabili slack possono assumere diversi valori:

- **Zero:** la soluzione del suo vincolo giace sulla frontiera.
- **Positivo:** la soluzione del suo vincolo giace nella regione ammissibile.
- **Negativo:** la soluzione del suo vincolo giace nella regione non ammissibile.

Proprietà di una soluzione di base:

1. **Variabile:** una variabile può essere o una variabile di base o una variabile non di base.

2. **Numero:** il numero delle variabili di base eguaglia il numero dei vincoli funzionali.
3. **Zero:** le variabili non di base vengono poste a zero.
4. **Valori:** i valori delle variabili di base sono ottenuti come risoluzione simultanea del sistema di equazioni lineari.
5. **Ammissibile:** se le variabili di base soddisfano i vincoli di non negatività, la soluzione di base è una soluzione ammissibile di base.

Due soluzioni di base ammissibili sono adiacenti se sono caratterizzate dal condividere le stesse variabili non di base eccetto una. Questo implica che tutte le loro variabili di base sono uguali eccetto una.

Tie breaking:

1. **Alternative multiple per la variabile entrante in base:** La scelta della variabile può essere effettuata arbitrariamente.
2. **Alternative multiple per la variabile uscente dalla base (degenerazione):**
 - a. **Variabili degeneri:** Se vengono scelte più variabili che raggiungono contemporaneamente il valore zero, quelle non selezionate usciranno comunque dalla base assumendo valore nullo nella nuova soluzione. In questo caso, si parla di variabili degeneri.
 - b. **Persistenza della degenerazione:** Una variabile degenera può mantenere valore nullo fino a un'iterazione successiva in cui viene scelta per uscire di base. In tale iterazione, la variabile entrante non può aumentare senza rendere negativa la variabile uscente, quindi rimane nulla e la funzione obiettivo non cambia.
 - c. **Possibile ciclo infinito:** Se la funzione obiettivo non varia ad ogni iterazione, il simplesso potrebbe ripetere ciclicamente la stessa sequenza di soluzioni, senza mai migliorare. Questo fenomeno, benché raro, è noto come loop perpetuo del simplesso, per cui sono state ideate strategie per prevenirlo.
3. **Mancanza di una variabile uscente (funzione obiettivo illimitata):** se non è possibile identificare una variabile uscente in quanto il test di ottimalità non lo consente (il test di ottimalità utilizza solo coefficienti positivi) allora il valore della soluzione è illimitato.
4. **Molteplici soluzioni ottimali:** ho più di una soluzione di base ottima se e solo se all'ottima ho almeno un coefficiente di costo ridotto associato a variabili (fuori base) uguale a 0. Posso effettuare un'operazione di pivot scegliendo come variabile entrante la variabile fuori base con coefficiente di costo ridotto = 0.

Teoria del simplesso:

Dato un problema di programmazione lineare con n variabili decisionali e regione ammissibile limitata allora:

- Un **vertice ammissibile** giace all'intersezione di n equazioni di frontiera.
- Uno **spigolo** della regione ammissibile è un segmento che giace all'intersezione di $n - 1$ equazioni di frontiera, dove ogni vertice estremo giace su un'equazione di frontiera addizionale (tale che gli estremi siano vertici ammissibili).
- Due vertici ammissibili sono adiacenti se il segmento che li collega è uno spigolo della regione ammissibile.

- Da ogni vertice ammissibile parte uno spigolo che conduce ad uno dei vertici ammissibili adiacenti.
- Ogni iterazione del metodo del simplesso si sposta dal vertice ammissibile corrente ad un vertice ammissibile adiacente muovendosi su questi spigoli.

Concetti chiave dell'algoritmo del simplesso:

1. Per ogni problema di programmazione lineare che ammetta almeno una soluzione ottimale, trovarne una, richiede di trovare solamente il vertice ammissibile cui compete il miglior valore della funzione obiettivo.
2. Il metodo del simplesso è un algoritmo iterativo con una inizializzazione che prevede la scelta di una soluzione e un test di ottimalità che serve a verificare la soluzione ottimale.
3. Se vi sono molte variabili decisionali, tali da rendere difficile usare il metodo grafico per scegliere la soluzione iniziale, scegliere l'origine evita di ricorrere a procedure algebriche per determinare la soluzione iniziale del metodo del simplesso.
4. Ad ogni iterazione, se l'algoritmo si sposta dal vertice corrente, verso un vertice con valore migliore della funzione obiettivo, lo fa per muoversi in un vertice a lui adiacente. Nessuna altra soluzione viene considerata.
5. Il metodo del simplesso valuta e compara i tassi di miglioramento della funzione obiettivo lungo la direzione degli spigoli che conducono dal vertice corrente ai vertici adiacenti. Il vertice selezionato diviene il nuovo vertice corrente.
6. L'ispezione di uno spigolo consente di identificare rapidamente il tasso di miglioramento di che si otterrebbe muovendosi lungo di esso verso la soluzione adiacente all'altro estremo. Il **test di ottimalità** consiste nel verificare se esiste uno spigolo con tasso positivo di miglioramento. Se tale condizione non è soddisfatta allora la soluzione corrente è ottimale.

Proprietà dei vertici ammissibili:

1. Esistenza:
 - a. se esiste solo una soluzione ottimale, allora questa è un vertice ammissibile
 - b. se esistono soluzioni ottime multiple (e la regione ammissibile è limitata) allora almeno due di queste soluzioni sono vertici ammissibili tra loro adiacenti.
2. Finitezza: esiste un numero finito di vertici ammissibili. Dati m vincoli funzionali e n vincoli di non negatività il numero di combinazioni di $m + n$ vincoli presi a gruppi di n è pari a
$$\binom{m+n}{n} = \frac{(m+n)!}{m!n!}$$
3. Se un vertice ammissibile non ammette vertici ammissibili a lui adiacenti che coincidono con soluzioni con valore migliore della funzione obiettivo Z , allora non esistono soluzioni ottimali migliori di quella che coincide con il vertice ammissibile in esame.

Prezzi ombra:

I prezzi ombra sono i valori delle variabili duali che indicano quanto varierebbe la funzione obiettivo del problema primale se si modificasse di un'unità il termine noto di un vincolo, rappresentano il "valore marginale" delle risorse.

Per il teorema della complementarità:

- Se un vincolo non è saturato, il suo prezzo ombra è zero.
- Se un prezzo ombra è positivo, il vincolo corrispondente è saturato.

Un vincolo si dice "non saturato" (o non attivo) quando nella soluzione ottima viene utilizzata una quantità di risorsa strettamente minore di quella disponibile. In altre parole, c'è un "avanzo" di quella risorsa.

Esempio:

$$\text{Max } Z = 40X_1 + 30X_2 \text{ (profitto)}$$

$$\text{S.t.} \quad 2X_1 + 3X_2 \leq 100 \text{ (ore lavoro)}$$

$$4X_1 + 2X_2 \leq 80 \text{ (materia prima)}$$

$$X_1, X_2 \geq 0$$

Supponendo che la soluzione ottima sia: $x_1 = 15$ $x_2 = 10$

Ore lavoro:

$$2(15) + 3(10) = 30 + 30 = 60$$

$60 < 100 \rightarrow$ Questo vincolo NON è saturato (abbiamo 40 ore non utilizzate).

Materia prima:

$$4(15) + 2(10) = 60 + 20 = 80$$

$80 = 80 \rightarrow$ Questo vincolo È saturato (utilizziamo tutta la materia prima).

Quindi per il vincolo delle ore di lavoro (non saturato) il prezzo ombra sarà $= 0$, infatti avere più ore disponibili non aumenterebbe il profitto, viceversa per il vincolo della materia prima (saturato) il prezzo ombra sarà maggiore > 0 , avere più materia prima permetterebbe di aumentare il profitto.

Dualità:

Ogni problema di programmazione lineare ha un altro problema associato che prende il nome di problema duale.

Proprietà della dualità debole: se x è una soluzione ammissibile per il problema primale e y è una soluzione ammissibile per il corrispondente problema duale, allora vale la seguente disuguaglianza: $cx \leq yb$. Il valore della funzione obiettivo primale è minore di quello della funzione obiettivo duale, per ogni coppia di soluzioni x e y ammissibili sia per il primale che per il duale.

Proprietà della dualità forte: se x^* è una soluzione ottimale per il problema primale allora y^* è una soluzione ottimale per il corrispondente duale, allora vale la seguente uguaglianza $cx^* = y^*b$. Il valore della funzione obiettivo del primale è uguale a quello della funzione obiettivo del duale.

Proprietà delle soluzioni complementari: ad ogni iterazione, il metodo del simplesso identifica simultaneamente una soluzione vertice ammissibile per il problema primale e una soluzione complementare per il problema duale tale che $cx = yb$. Se x non è ottimale per il problema primale allora y non è ammissibile per il problema duale.

Proprietà delle soluzioni ottimali complementari: all'iterazione finale, il metodo del simplesso identifica simultaneamente una soluzione ottimale x^* per il problema primale e una soluzione ottimale complementare y^* per il problema duale dove $cx^* = y^*b$. Le componenti y_i^* sono i prezzi ombra del problema primale.

Proprietà di simmetria: per ogni problema primale e relativo problema duale, tutte le relazioni tra loro debbono essere simmetriche in quanto, il problema duale del problema duale è il problema primale.

Proprietà delle soluzioni aumentate complementari: ogni soluzione di base del primale ha una soluzione di base complementare nel problema duale, in modo tale che i rispettivi valori delle funzioni obiettivo siano uguali.

Proprietà di complementary slackness: per ogni coppia di variabili associate, se una di loro ha una variabile slack nel suo vincolo di non negatività (una variabile di base ≥ 0), allora l'altra non deve avere slack (una variabile non di base $= 0$).

Teorema di dualità: le sole relazioni possibili tra problema primale e duale sono le seguenti:

1. Se un problema ha **soluzioni ammissibili e funzione obiettivo limitata** (pertanto tale da avere soluzione ottimale), allora la stessa cosa vale per l'altro problema, per cui sia la proprietà debole della dualità che la proprietà forte della dualità sono applicabili.
2. Se un problema ha **soluzioni ammissibili e funzione obiettivo illimitata** (pertanto tale da non avere soluzione ottimale), allora l'altro problema non ha soluzioni ammissibili.
3. Se un problema **non ha soluzioni ammissibili**, allora l'altro problema o non ha soluzioni ammissibili o ha una funzione obiettivo illimitata.

Relazione tra soluzioni di base complementari: le soluzioni sono classificabili in base al fatto che soddisfino o meno una delle seguenti condizioni:

- **Condizione di ammissibilità:** se tutte le variabili (incluse le variabili slack), della soluzione aumentata, sono non negative.
- **Condizione di ottimalità:** se i coefficienti nella riga 0 (tutte le variabili della soluzione di base complementare) sono non negativi.

		soddisfa la condizione di ottimalità?	
		SI	NO
ammissibile?	SI	ottimale	sub-ottimale
	NO	super-ottimale	ne ammissibile ne super-ottimale

- **Né ammissibile né ottimale:** se la soluzione del problema primale risulta inammissibile e la corrispondente soluzione del problema duale anche.
- **Sub-ottimale:** se la soluzione del problema primale risulta ammissibile mentre la corrispondente soluzione del problema duale no.
- **Super-ottimale:** se la soluzione del problema primale risulta inammissibile e la corrispondente soluzione del problema duale ammissibile.
- **Ottimale:** se sia la soluzione del problema primale che quella del problema duale risulta ammissibile.

Ricavare una soluzione ottima alternativa a quella ricavata

attraverso il simplesso: Ho più di una soluzione di base ottima se e solo se all'ottima ho almeno un coefficiente di costo ridotto associato a variabili **fuori base uguale** a 0. Posso quindi effettuare un'altra iterazione del metodo del simplesso scegliendo come variabile entrante la variabile fuori base con coefficiente di costo ridotto = 0.

Ricavare una soluzione ugualmente ottima ma non di base:

posso ricavare una soluzione ugualmente ottima ma non di base attraverso una combinazione convessa nel seguente modo (**devo avere a disposizione due soluzione ottime di base**) :

$$\lambda \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{pmatrix} + (1 - \lambda) \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{pmatrix}$$

Con λ scelto arbitrariamente in $(0,1)$

Esempio:

$$\lambda \in (0,1)$$

$$\lambda = 1/2$$

$$\begin{pmatrix} \frac{1}{2} * x_1 \\ \frac{1}{2} * x_2 \\ 0 \\ 0 \\ 0 \end{pmatrix} + \begin{pmatrix} \frac{1}{2} * x_1 \\ 0 \\ 0 \\ 0 \\ \frac{1}{2} * x_5 \end{pmatrix} = \begin{pmatrix} \frac{1}{2} * x_1 + \frac{1}{2} * x_1 \\ \frac{1}{2} * x_2 \\ 0 \\ 0 \\ \frac{1}{2} * x_5 \end{pmatrix}$$

Programmazione lineare intera:

Nella **programmazione lineare intera** le variabili di decisione assumono valori interi; tuttavia, se solo alcune delle variabili di decisione devono essere intere allora si parla di **programmazione lineare mista**.

Ottimizzazione intera e binaria:

Consideriamo un generico problema di programmazione lineare con n variabili e m vincoli

$$\text{opt } f(x) = c^T x \text{ (funzione obiettivo lineare)}$$

Avremo:

- Variabili binarie, dunque che assumono solo valore 0 o 1.
- Vincoli di budget, come nei problemi di programmazione lineare.
- Vincolo di mutua esclusione tra le variabili, rappresentabile nel seguente modo $x_i + x_j \leq 1$
- Condizione di contingenza: se vogliamo che un valore sia contenuto rispetto ad un altro: $x_i \leq x_j$
- Funzione obiettivo da massimizzare o da minimizzare.

Condizioni logiche:

Le variabili binarie consentono di introdurre condizioni logiche:

Vincolo del tipo either-or:

Dati due vincoli, almeno uno di questi deve essere soddisfatto. Allora è possibile scrivere i due vincoli aggiungendo al termine noto della prima equazione M^*y e nell'altra equazione $M^*(1 - y)$, dove M è un numero positivo molto grande e y è una variabile binaria:

- Se $y = 0$ allora la prima equazione rimane invariata, mentre la seconda può essere eliminata in quanto sempre soddisfatta dato che M è molto grande.
- Se $y = 1$ allora la seconda equazione rimane invariata, mentre la prima può essere eliminata in quanto sempre soddisfatta per M molto grande.

Dati N vincoli solo K sono presenti:

Il modello include N vincoli ma solo K vincoli devono essere soddisfatti (con $K < N$), consideriamo N variabili binarie $y_i \in \{0,1\}$ per $i = 1, \dots, N$ ed un numero M molto grande, allora abbiamo la seguente formulazione:

$$\begin{cases} f_1(x_1, x_2, \dots, x_n) \leq d_1 + My_1 \\ f_2(x_1, x_2, \dots, x_n) \leq d_2 + My_2 \\ \dots \\ f_N(x_1, x_2, \dots, x_n) \leq d_N + My_N \\ \sum_{i=1}^n y_i = N - K \end{cases}$$

La funzione assume solo N possibili valori

Si consideri la situazione in cui una data funzione assuma uno fra N possibili valori.

$$d(x_1, x_2, \dots, x_n) = d_1 \text{ o } d_2, \dots, \text{ o } d_n$$

Consideriamo N variabili binarie $y_i \in \{0,1\}$ per $i = 1, \dots, N$ si ottiene la seguente formulazione equivalente al requisito che una data funzione assuma uno fra N possibili valori.

$$\begin{cases} f(x_1, x_2, \dots, x_n) = \sum_{i=1}^N d_i y_i \\ \sum_{i=1}^N y_i = 1 \end{cases}$$

Problema del costo fisso

Supponiamo che si voglia intraprendere un'attività j il cui costo sia caratterizzato dalla seguente funzione:

$$f(x) = \begin{cases} k + cx & \text{se } x > 0 \\ 0 & \text{se } x = 0 \end{cases}$$

Dove $k > 0$ denota il costo fisso, $x \geq 0$ è il livello di attività e c è il costo per ogni unità incrementale. La minimizzazione di tale funzione può essere espressa attraverso il seguente modello di PLI:

$$\min z = (ky + cx)$$

Soggetto ai seguenti vincoli:

$$\begin{cases} x - My \leq 0 \\ y \in \{0,1\} \text{ e } x \geq 0 \end{cases}$$

Dove M denota un numero molto grande:

- Se $y = 0$ allora si ha $x \leq 0 \rightarrow x = 0$ e $z = 0$
- Se $y = 1$ allora $x \leq M$, ovvero x può assumere un qualsiasi valore e $z = k + cx$

Rilassamento lineare:

Il rilassamento lineare è una tecnica utilizzata nella risoluzione dei problemi di programmazione lineare intera, consiste nel rimuovere il vincolo di interezza delle variabili dal problema originale trasformandolo in un problema di programmazione lineare standard. Il rilassamento lineare per un problema di PLI è utile allo scopo di verificare se la soluzione ottima trovata sia intera, nel qual caso viene trovata la soluzione ottima; in caso contrario si ottiene un upper bound per i problemi di massimo e un lower bound per i problemi di minimo. Vi sono casi particolari in cui risolvere un problema PLI non è più difficile di risolvere un problema PL, ovvero quando la soluzione ottima del problema rilassato è una soluzione intera. (In questo caso la soluzione del rilassamento lineare DEVE necessariamente essere ottima anche per il problema PLI). Non vi è nessuna garanzia che la soluzione ottima di un problema PLI corrisponda alla soluzione approssimata del rilassamento lineare.

Metodo del branch and bound:

Il metodo del branch and bound è una tecnica generale per la risoluzione di problemi di ottimizzazione intera, in particolare una tecnica di enumerazione implicita, ovvero:

- Valuta le soluzioni possibili fino a trovare quella ottima.
- Scarta alcune di queste soluzioni a priori, dimostrando la loro non ottimalità.

L'algoritmo Branch and bound utilizza principalmente tre tecniche per risolvere un generico problema di PLI:

- **Branching**: la partizione rispetto al valore delle variabili
- **Bounding**: la determinazione di un limite superiore
- **Fathoming**: l'eliminazione di sottoproblemi

Branching dei problemi

Il branching consiste nel suddividere il problema iniziale in sotto-problemi più piccoli, partizionando la regione ammissibile in sotto-regioni attraverso la selezione di una variabile decisionale e imponendo vincoli disgiunti su di essa. Nel caso di **problemi con variabili binarie** il modo più semplice per dividere l'insieme delle soluzioni ammissibili in sottoinsiemi è fissare il valore di una delle variabili, per esempio $x_1 = 0$, per un sottoinsieme e $x_1 = 1$ per l'altro sottoinsieme. La variabile che viene utilizzata per seguire questa suddivisione ad ogni iterazione è chiamata **variabile di branching**. Invece nel caso di problemi con variabili non binarie la variabile di branching corrisponde alla variabile non intera.

In caso ci sia una scelta multipla si possono applicare le seguenti convenzioni:

- Variabile con la parte frazionaria maggiore
- Variabile con l'indice più basso

Bounding

Il bounding consiste nel ricavare **un limite superiore** nel caso il problema sia di **massimizzazione**, un limite **inferiore** nel caso il problema sia di **minimizzazione** per il valore della funzione obiettivo in ciascun sotto-problema. Il limite aiuta a stabilire se un sotto-problema può essere chiuso oppure se necessita di essere esplorato ulteriormente.

Per ottenere questo limite si risolve il problema rilassato, ovvero il problema senza i vincoli di interezza. Nel caso di problemi binari i valori delle variabili vengono limitati a (0 e 1).

Fathoming

Un sotto-problema può essere eliminato dalla lista dei problemi utilizzando tre criteri:

1. Se il valore della soluzione ottimale del nodo corrente è peggiore del valore della soluzione ottimale globale, il nodo viene scartato.
 - a. Se il problema è di massimizzazione: $UB \leq Z^*$
 - b. Se il problema è di minimizzazione: $UB \geq Z^*$
2. Se la soluzione trovata è intera ovvero se il nodo produce una soluzione ammissibile che soddisfa tutti i vincoli di integrità e il suo valore è migliore della soluzione ottimale corrente.
3. Il sotto-problema non ammette soluzioni ammissibili.

Strategie di visita dei nodi:

Sotto-problema creato più di recente (Depth First):

La selezione attraverso il metodo depth first ha il vantaggio di facilitare la ripresa dell'ottimizzazione del rilassamento poiché richiede solo l'aggiunta di un nuovo vincolo al problema precedente. Questo metodo è semplice da implementare e permette di ottenere delle soluzioni ammissibili velocemente,

inoltre limita l'utilizzo della memoria necessaria a memorizzare l'albero delle soluzioni in quanto che si tendono a chiudere numerosi nodi per ammissibilità e rimangono pochi nodi contemporaneamente aperti. Un aspetto negativo di questa strategia consiste nella possibile esplorazione completa di sotto-alberi con soluzioni scadenti.

Sotto-problema con il miglior bound (Depth First):

La selezione attraverso il metodo best-bound in genere conduce a soluzioni incombenti più velocemente e quindi permette di effettuare un fathoming più efficiente.

Tipicamente, tale strategia permette di limitare il numero di nodi visitati esplicitamente ma l'esplorazione tende a rimanere a livelli poco profondi dove i problemi sono meno vincolati e, di conseguenza, i bound sono più promettenti ma difficilmente si ottengono presto soluzioni ammissibili che migliorino la soluzione incombente corrente.

È possibile utilizzare anche una combinazione dei due approcci in modo tale da sfruttare i vantaggi di ogni approccio.

Programmazione non lineare:

Un problema di programmazione non lineare può essere formulato come:

$$\text{opt } f(x)$$

soggetto ai seguenti vincoli:

$$g_{j(x)} \leq 0 \text{ con } j = 1, \dots, m$$

$$x_i \geq 0 \text{ con } i = 1, \dots, n$$

Dove con $\text{opt} = \begin{cases} \min \\ \max \end{cases}$ si intende che $\text{opt} = \min$ oppure $\text{opt} = \max$

A seconda delle caratteristiche del problema esistono diversi tipi di programmazione non lineare

Ottimizzazione non vincolata: i problemi di ottimizzazione non vincolata non hanno vincoli sulla regione ammissibile; pertanto, l'obiettivo è semplicemente

$$\max f(x) \text{ oppure } \min f(x) \text{ con } x \in R^n$$

Ottimizzazione con vincoli lineari: i problemi di ottimizzazione con vincoli lineari sono caratterizzati da tutte le funzioni $g_i(x)$ lineari ma dalla funzione obiettivo non lineare.

Ottimizzazione convessa: nell'ottimizzazione convessa ogni funzione $f(x)$ è una funzione concava o convessa e ogni funzione $g_i(x)$ è convessa.

Ottimizzazione non convessa: I problemi di programmazione non convessa comprendono tutti i problemi che non soddisfano le ipotesi di convessità. Sono più difficili da risolvere perché possono presentare diversi punti di minimo/massimo.

Ottimizzazione non lineare in una variabile:

Massimizzazione di funzioni concave

Considero un problema di massimizzazione con una funzione obiettivo concava da **massimizzare**,

$$\max f(x) \text{ con } x \in R^n$$

La condizione sufficiente affinché x^* sia un punto di massimo è che:

$$\frac{df(x^*)}{dx} = 0$$

Se tale equazione può essere risolta analiticamente allora il procedimento per trovare l'ottimo termina. Il procedimento è identico per un problema di **minimizzazione** e una funzione **convessa**.

In mancanza di una risoluzione analitica dell'equazione sono disponibili algoritmi per la risoluzione numerica del problema.

Criteri di arresto

A differenza dell'algoritmo del semplice, in questo caso la sequenza di punti $\{x_k\}$ non è detto che converga alla soluzione ottima del problema in un numero finito di iterazioni.

Conviene fermare la sequenza di punti quando:

- La soluzione è sufficientemente accurata $\frac{df(x_k)}{dx} \approx 0$
- Quando si è raggiunto un numero di iterazioni N o un tempo computazionale massimo
- I progressi sono lenti ovvero $|x_{k+1} - x_k| < \epsilon_x$ oppure $|f(x_{k+1}) - f(x_k)| < \epsilon_f$
- La soluzione diverge ($|x_k| \rightarrow +\infty$)
- Si verificano dei cicli

Esistono due tipi di algoritmi:

- **Dicotomici**: algoritmi di ricerca per individuare un determinato valore (per il quale la funzione derivata si annulla) all'interno di un intervallo che ad ogni iterazione viene ridotto.
- **Di approssimazione**: utilizzano approssimazioni locali della funzione

Gli algoritmi per l'ottimizzazione di funzioni in una variabile sono:

- **Metodo di bisezione** (algoritmo dicotomico)
- **Metodo di newton** (algoritmo di approssimazione)

Metodo di bisezione:

Se $f(x)$ è continua e concava in un intervallo chiuso $[a, b]$ allora, considerando un generico punto x_k :

- Se $\frac{df(x_k)}{dx} < 0$ allora il punto ottimo x^* si trova a sinistra di x_k
- Se $\frac{df(x_k)}{dx} > 0$ allora il punto ottimo x^* si trova a destra di x_k
- Se $\frac{df(x_k)}{dx} \approx 0$ allora $x_k \approx x^*$

Considero un generico punto x_k

- Se $f'(x_k) > 0$ allora x_k rappresenta un estremo inferiore $\underline{x}$ per il punto x^* .
- Se $f'(x_k) < 0$ allora x_k rappresenta un estremo superiore $\bar{x}$ per il punto x^* .

Ad ogni iterazione k posso identificare un sotto-intervallo di ricerca $[a_k, b_k] \subset [a_{k-1}, b_{k-1}] \subset [a, b]$ per ridurre lo spazio di ricerca in modo da identificare un'iterazione k per cui $|b_k - a_k| < 2\epsilon$ con $|a_k - x^*| < \epsilon$ e $|x^* - b_k| < \epsilon$

Algoritmo di bisezione per problemi di massimo e di minimo:

Inizializzazione

$k = 0$ e ϵ piccolo a piacere

Si determinano i valori dell'estremo inferiore e dell'estremo superiore cercando dei valori di x per cui la derivata sia rispettivamente positiva e negativa.

Si seleziona il punto iniziale $x_0 = \frac{\bar{x} + \underline{x}}{2}$

Iterazione del metodo di bisezione per problemi di massimo:

- Calcolare $f'(x)$
- Se $f'(x) = 0$ allora $x_k = x^*$
- Altrimenti se $f'(x) < 0$ allora $\bar{x} = x_k$
- Altrimenti se $f'(x) > 0$ allora $\underline{x} = x_k$
- Pongo $x_{k+1} = \frac{\bar{x} + \underline{x}}{2}$ e $k = k + 1$

Iterazione del metodo di bisezione per problemi di minimo:

- Calcolare $f'(x)$
- Se $f'(x) = 0$ allora $x_k = x^*$
- Altrimenti se $f'(x) > 0$ allora $\bar{x} = x_k$
- Altrimenti se $f'(x) < 0$ allora $\underline{x} = x_k$
- Pongo $x_{k+1} = \frac{\bar{x} + \underline{x}}{2}$ e $k = k + 1$

Criterio di arresto: se $\bar{x} - \underline{x} \leq 2\epsilon$ allora il punto di ottimo x^* avrà distanza minore di ϵ da $\underline{x}$ o $\bar{x}$, altrimenti si esegue una nuova iterazione del metodo di bisezione.

Approssimazione quadratica:

Il metodo di newton converge molto lentamente se utilizza solo l'informazione relativa alla derivata prima $f'(x)$, per aumentare la velocità di convergenza è necessario considerare anche la derivata seconda $f''(x)$. Tramite il polinomio di Taylor (centrato in x_k) è possibile ottenere un'approssimazione quadratica di tale funzione.

$$f(x_{k+1}) \approx f(x_k) + f'(x_k)(x_{k+1} - x_k) + \frac{1}{2}f''(x_k)(x_{k+1} - x_k)^2$$

L'approssimazione quadratica è una funzione solo di x_{k+1} . Si calcola la derivata dell'approssimazione quadratica:

$$f'(x_k) + f''(x_k)(x_{k+1} - x_k) = 0$$

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

Questa formula viene utilizzata ad ogni generica iterazione k per calcolare il punto successivo x_{k+1}

Se $f(x)$ è concava allora x_k converge verso un punto di massimo

- Se $f(x)$ è concava allora se x_k si trova a sinistra del punto massimo $\rightarrow f'(x) > 0$ e quindi $x_{k+1} > x_k$
- Se $f(x)$ è concava allora se x_k si trova a destra del punto massimo $\rightarrow f'(x) < 0$ e quindi $x_{k+1} < x_k$

Se $f(x)$ è convessa allora x_k converge verso un punto di minimo

Algoritmo di newton:

Inizializzazione

Si fissa ϵ e $k = 0$

Iterazione del metodo di newton

- Calcolare $f'(x_k)$ e $f''(x_k)$
- Porre $x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$

Criterio di arresto: se $|x_{k+1} - x_k| \leq \epsilon$ allora il $x_{k+1} = x^*$ è la soluzione ottima, altrimenti si esegue una nuova iterazione del metodo di Newton e si pone $k = k + 1$.

Confronto bisezione e newton:

Bisezione:

- **Vantaggi:** richiede solo il calcolo della derivata prima e converge sempre
- **Svantaggi:** lentezza

Newton

- **Vantaggi:** la velocità di convergenza è quadratica
- **Svantaggi:** richiede il calcolo della derivata seconda, inoltre talvolta potrebbe divergere

Programmazione non lineare multivariata non vincolata:

Gradiente:

Sia $f: \mathbb{R}^n \rightarrow \mathbb{R}$ una funzione reale, il gradiente di f in x corrisponde al vettore delle derivate parziali

$$\nabla f(x) = \left[\frac{\partial f(x)}{\partial x_1} \quad \frac{\partial f(x)}{\partial x_2} \quad \dots \quad \frac{\partial f(x)}{\partial x_n} \right]$$

Derivate parziali:

La derivata parziale di $f(x, y)$ rispetto alla variabile x è data dalla derivata della funzione $f(x, y)$ rispetto a x trattando le altre variabili come costanti. Si indica con la seguente notazione:

$$\frac{\partial f}{\partial x} = f_x = f'_x$$

La derivata parziale di $f(x, y)$ rispetto alla variabile y è data dalla derivata della funzione $f(x, y)$ rispetto a y trattando le altre variabili come costanti. Si indica con la seguente notazione:

$$\frac{\partial f}{\partial y} = f_y = f'_y$$

Derivate parziali del secondo ordine:

Calcolando la derivata parziale rispetto a una delle variabili della derivata parziale della funzione $f(x, y)$ rispetto a una delle variabili si ottiene la derivata parziale del secondo ordine. Le possibili derivate parziali del secondo ordine sono:

1. Derivata parziale seconda rispetto a x_1 e x_1 :

$$\frac{\partial}{\partial x_1} \left(\frac{\partial f(x_1, x_2)}{\partial x_1} \right) = f_{x_1 x_1} = f''_{x_1 x_1}$$

2. Derivata parziale seconda rispetto a x_1 e x_2 :

$$\frac{\partial}{\partial x_2} \left(\frac{\partial f(x_1, x_2)}{\partial x_1} \right) = f_{x_1 x_2} = f'_{x_1 x_2}$$

3. Derivata parziale seconda rispetto a x_2 e x_1 :

$$\frac{\partial}{\partial x_2} \left(\frac{\partial f(x_1, x_2)}{\partial x_2} \right) = f_{x_2 x_1} = f'_{x_2 x_1}$$

4. Derivata parziale seconda rispetto a x_2 e x_2 :

$$\frac{\partial}{\partial x_2} \left(\frac{\partial f(x_1, x_2)}{\partial x_2} \right) = f_{x_2 x_2} = f''_{x_2 x_2}$$

Matrice Hessiana:

Le derivate parziali del secondo ordine possono anche essere rappresentate attraverso la matrice Hessiana

$$\mathbb{H} = \begin{bmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{bmatrix}$$

Calcolo degli autovalori di una matrice:

Per calcolare gli autovalori di una matrice 2×2 si eseguono i seguenti passaggi:

1. Calcolo del determinante caratteristico $|A - \lambda I| = 0$ dove:
 - A è la matrice data
 - λ è l'incognita (l'autovalore)
 - I è la matrice identità

Nel caso di una **matrice diagonale** (una matrice che ha tutti zero fuori dalla diagonale) gli autovalori sono i numeri che si trovano sulla diagonale principale.

Nel caso della matrice hessiana:

1. Calcolo del determinante caratteristico $|\mathbb{H} - \lambda I| = 0$
2. Per una matrice hessiana 2×2 :

$$\det(\mathbb{H} - \lambda I) = \begin{vmatrix} \frac{\partial^2 f}{\partial x^2} - \lambda & \frac{\partial^2}{\partial x \partial y} \\ \frac{\partial^2}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} - \lambda \end{vmatrix}$$

Sviluppando il determinante ottengo:

$$\left(\frac{\partial^2}{\partial x^2} - \lambda\right)\left(\frac{\partial^2 f}{\partial y^2} - \lambda\right) - \left(\frac{\partial^2}{\partial x \partial y}\right)\left(\frac{\partial^2}{\partial y \partial x}\right) = 0$$

Matrici definite positive e negative:

- Una matrice quadrata è **definita positiva** se tutti gli autovalori della matrice sono positivi
- Una matrice quadrata è **definita negativa** se tutti gli autovalori della matrice sono negativi
- Una matrice quadrata è **semi-definita positiva** se tutti gli autovalori della matrice sono non negativi
- Una matrice quadrata è **semi-definita negativa** se tutti gli autovalori della matrice sono non positivi
- Una matrice quadrata è indefinita se ad esempio gli autovalori assumono i seguenti valori ($\lambda_1 = -5, \lambda_2 = -2, \lambda_3 = 8$)

Legame tra matrice Hessiana e concavità/convessità

Gli autovalori della matrice hessiana sono importanti perché forniscono delle informazioni sulla concavità/convessità della funzione:

- Se tutti gli autovalori sono > 0 , la funzione è **convessa**
- Se tutti gli autovalori sono < 0 , la funzione è **concava**

Trovare i punti di massimo

Per cercare i **punti stazionari** è necessario porre il gradiente della funzione uguale a zero, i punti trovati possono essere candidati punti di massimo o di minimo.

$$\nabla f = 0$$

Una volta trovati i punti, si valuta la matrice Hessiana in quei punti:

Si calcola il determinante della matrice quadrata: $DET = ad - bc$

Si calcola la traccia (**somma degli elementi sulla diagonale principale**) $(\lambda_1 + \lambda_2)$

- Se $DET > 0$ e la TRACCIA > 0 λ_1 e λ_2 sono positivi $\rightarrow Hf$ è definita positiva
- Se $DET > 0$ e la TRACCIA < 0 λ_1 e λ_2 sono negativi $\rightarrow Hf$ è definita negativa
- Se $DET > 0$ e la TRACCIA > 0 λ_1 e λ_2 sono non negativi $\rightarrow Hf$ è semi-definita positiva
- Se $DET > 0$ e la TRACCIA < 0 λ_1 e λ_2 sono non positivi $\rightarrow Hf$ è semi-definita negativa
- Se $DET < 0$ allora Hf né semi-definita positiva, né semi-definita negativa

Se la matrice è **definita positiva** allora il punto è di **minimo**

Se la matrice è **definita negativa** allora il punto è di **massimo**

ESEMPIO:

$$\begin{bmatrix} 4 & 8 \\ 8 & 20 \end{bmatrix}$$

$$Det = (4 \cdot 20) - (8 \cdot 8) = 16$$

$$Traccia = 4 + 20 = 24$$

$$16 = \lambda_1 * \lambda_2$$

$$24 = \lambda_1 + \lambda_2$$

Siccome λ_1 e λ_2 deve essere uguale a 16, i valori di lambda possono essere sia positivi che negativi; tuttavia, siccome la traccia della matrice deve essere uguale a 24 si può dedurre che entrambi i valori λ_1 e λ_2 sono positivi. La matrice quindi è definita positiva.

In generale se non si hanno informazioni globali circa la **convessità** o meno di una funzione non è possibile stabilire se un punto **di minimo/massimo locale è anche globale**.

Siccome nel caso generale le equazioni ottenute ponendo il gradiente = 0 non sono lineari e possono essere complicate da risolvere, ci sono degli algoritmi risolutivi appositi:

- Metodo del **gradiente** (steepest descent)
- Metodo di **Newton**

Questi algoritmi appartengono all'insieme delle strategie di tipo line-search che generano una successione di punto x_k all'interno dello spazio R^n in modo che il punto x_{k+1} è ottenuto a partire dal punto x_k muovendosi lungo una **direzione di salita** (in caso di massimo) o **di discesa** (in caso di minimo).

Algoritmo per un generico metodo line-search:

Considero una generica funzione $f: \mathbb{R}^n \rightarrow \mathbb{R}$, ed un generico punto $x \in \mathbb{R}^n$ in cui la funzione risulti differenziabile. Una funzione risulta **differenziabile** se tutte le derivate prime esistono in un intorno del punto x e se la funzione può essere approssimata linearmente intorno al punto x , cioè esiste una

trasformazione lineare (matrice jacobiana) che approssima il comportamento della funzione vicino al punto.

Per cercare un generico punto di minimo della funzione f è possibile usare la seguente strategia

- Porre $k = 0$ e considerare un generico punto x^k
- Determinare una direzione di discesa d^k
- Cercare un nuovo punto x^{k+1} lungo la direzione d^k

$$x^{k+1} = x^k + a^k + d^k$$

Dove k è la generica iterazione e $a^k > 0$ è una quantità scalare chiamata **step-size**

Step size:

$$x^{k+1} = x^k + a^k + d^k$$

Si vuole minimizzare/massimizzare il valore della funzione $f(x^{k+1}) = f(x^k + a^k d^k)$, ovvero la restrizione della funzione $f(x)$ lungo la direzione d^k . x^k è il punto corrente d^k è la direzione corrente, sono entrambi fissati, quindi la sola variabile è a^k .

Per trovare a^k è possibile porre

$$\frac{df(x^k + a^k d^k)}{da^k} = 0$$

Ed usare un metodo di minimizzazione/massimizzazione per trovare a^k ottimale.

Metodo del gradiente:

Il metodo del gradiente è un metodo line-search che utilizza

- Come direzione di crescita $d^k = \nabla f(x^k)$ per i problemi di massimo
- Come direzione di decrescita $d^k = -\nabla f(x^k)$ per i problemi di minimo

La generica iterazione del metodo del gradiente è:

$$\begin{pmatrix} x_{k+1} \\ y_{k+1} \end{pmatrix} = \begin{pmatrix} x_k \\ y_k \end{pmatrix} \pm \alpha \begin{pmatrix} \frac{f(x_k, y_k)}{\partial x} \\ \frac{f(x_k, y_k)}{\partial y} \end{pmatrix}$$

Con $\alpha > 0$

Il Simbolo $\pm$ dipende dal tipo di operazione che si sta effettuando, per i problemi di **minimizzazione** si utilizza il segno $-$, mentre per i problemi di **massimizzazione** il segno $+$.

Algoritmo del gradiente

Inizializzazione: si pone $k = 0$ e si considera un generico punto x^k

1. Calcolo del gradiente di $f(x, y)$:

$$\frac{f(x, y)}{\partial x}$$

$$\frac{f(x, y)}{\partial y}$$

$$\nabla f(x, y) = \left[\frac{f(x, y)}{\partial x}, \frac{f(x, y)}{\partial y} \right]^t$$

2. Calcolo il gradiente nel punto corrente (x, y) .
3. Utilizzo la formula della generica iterazione del metodo del gradiente facendo attenzione alla scelta del simbolo ($-$ per problemi di minimizzazione, $+$ per problemi di massimizzazione) ed ottengo il nuovo punto.
4. Il problema di ottimizzazione è dato da $\alpha^* = \min/\max f(\alpha)$ dove $f(\alpha)$ corrisponde al nuovo punto trovato utilizzando la formula della generica iterazione.
5. Sostituisco il nuovo punto trovato nella funzione di partenza.
6. Si calcola α^* come soluzione di

$$f'(x^k + \alpha^k \nabla f(x^k)) = 0$$

Utilizzando un metodo di ottimizzazione per funzioni in una variabile

7. **Criterio di arresto:** se $|f(x^{k+1}) - f(x^k)| < \epsilon$ oppure $||\nabla f(x^{k+1})|| < \epsilon_2$ allora si ferma, altrimenti si esegue una nuova iterazione ponendo $k = k + 1$ e si riparte dal punto 2.

Metodo di newton:

Il metodo di newton prevede un'approssimazione della funzione nell'intorno del punto corrente con una funzione quadratica (polinomio di Taylor) che viene ottimizzata per ottenere un nuovo punto.

$$f(x^k + \Delta x) = f(x^k) + \nabla f(x^k) \Delta x + \frac{1}{2} \Delta x H_f(x^k) \Delta x$$

Si cerca una direzione di miglioramento che ottimizza la funzione del nuovo punto $(x^k + \Delta x)$.

Tenendo presente che $\Delta x = x^{k+1} - x^k$

1. $k = 0$, si sceglie un punto iniziale x^k
2. Si calcola $\nabla f(x^k)$ e $H_f(x^k)^{-1}$
3. Si calcola il nuovo punto usando la seguente equazione

$$x^{k+1} = x^k - H_f(x^k)^{-1} \cdot \nabla f(x^k)$$

4. Si usano i criteri di convergenza (gli stessi del metodo del gradiente). Se non vengono rispettati allora si procede con un'ulteriore iterazione $k = k + 1$ e si torna al punto 2.

Il metodo di newton utilizza sia il gradiente che la matrice hessiana ad ogni iterazione, se converge, converge molto più velocemente del metodo del gradiente; tuttavia, ogni iterazione richiede una computazione più complicata. In caso di funzioni quadratiche il metodo di newton converge in una iterazione.

Come calcolare $-H_f(x, y)^{-1} \nabla f(x_k, y_k)$?

Il calcolo di $-H_f(x, y)^{-1} \nabla f(x_k, y_k)$? Richiederebbe a priori di calcolare:

1. La matrice hessiana nel punto corrente
2. Il gradiente nel punto corrente
3. Calcolare l'inversa della matrice hessiana nel punto
4. Moltiplicare l'inversa della matrice hessiana per il gradiente

Un modo per evitare tale calcolo è basato sulla seguente considerazione, ovvero sul fatto che non importa conoscere il valore di $H_f(x, y)^{-1}$:

$$-H_f(x, y)^{-1} \nabla f(x_k, y_k) = \begin{pmatrix} v_1 \\ v_2 \end{pmatrix}$$

Il vettore $\begin{pmatrix} v_1 \\ v_2 \end{pmatrix}$ può essere calcolato come soluzione del sistema:

$$H_{f(x,y)} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = -\nabla f(x_k, y_k)$$

Dopo aver risolto l'equazione, il punto trovato andrà **sommato** al punto corrente sia nel caso di problemi di massimizzazione che di minimizzazione.

Programmazione non lineare vincolata:

Considero un problema di programmazione non lineare vincolata

$$opt f(x)$$

Soggetto ai seguenti vincoli:

$$g_i(x) = 0 \text{ con } i = 1, \dots, m \text{ vincoli di uguaglianza}$$

$$h_j(x) \leq 0 \text{ con } j = 1, \dots, p \text{ vincoli di disuguaglianza}$$

Con $opt = \begin{Bmatrix} min \\ max \end{Bmatrix}$ quindi opt può essere un problema di minimizzazione o di massimizzazione.

Per affrontare questo problema ci sono tre approcci differenti:

- Riduzione del numero di variabili libere (dimensionality reduction)
- Metodo dei moltiplicatori di Lagrange
- Condizione di Karush-Kuhn-Tucker

Dimensionality reduction:

Nel caso in cui si abbia un problema di ottimizzazione soggetto ad un certo numero l di vincoli di uguaglianza è possibile esplicitare l variabili in funzione delle restanti $n - l$ variabili utilizzando i vincoli di uguaglianza del problema, così facendo è possibile trasformare il problema in un problema di ottimizzazione non vincolata con $n - l$ variabili.

Lagrangiana:

Considerando un generico problema di programmazione non lineare vincolata con solo vincoli di uguaglianza.

$$\text{opt } f(x_1, \dots, x_n)$$

Soggetto ai seguenti vincoli:

$$g_i(x_1, \dots, x_n) = 0 \text{ con } i = 1, \dots, m$$

Con $\text{opt} = \begin{cases} \min \\ \max \end{cases}$ quindi opt può essere un problema di minimizzazione o di massimizzazione.

Considero la funzione in $m + n$ variabili

$$L(x_1, \dots, x_n, \lambda_1, \dots, \lambda_m) = f(x_1, \dots, x_n) + \sum_{i=1}^m \lambda_i \cdot g_i(x_1, \dots, x_n)$$

Tale funzione prende il nome di funzione **Lagrangiana**, mentre le variabili λ_i (tante quante sono i vincoli) prendono il nome di moltiplicatori di Lagrange.

Metodi dei moltiplicatori di Lagrange:

Considero un generico problema di ottimizzazione non lineare del tipo

$$\text{opt } f(x_1, \dots, x_n)$$

Soggetti ai seguenti vincoli di uguaglianza:

$$g_i(x_1, \dots, x_n) = 0 \text{ con } i = 1, \dots, m$$

Sia $x^* = (x_1^*, \dots, x_n^*)$ il punto stazionario di f , allora esistono m moltiplicatori di Lagrange $\lambda^* = (\lambda_1^*, \dots, \lambda_m^*)$ tali che (x^*, λ^*) è un punto stazionario della Lagrangiana associata

$$L(x^*, \lambda^*) = f(x^*) + \sum_{i=1}^m \lambda_i^* \cdot g_i(x^*)$$

Osservazioni

- I punti x^* e (x^*, λ^*) possono essere punti stazionari di tipo diverso (massimo, minimo, di sella).
- Tale condizione fornisce una condizione necessaria ma non sufficiente per l'ottimizzazione del problema vincolato.

Condizioni del primo ordine

Sia $x^* = (x_1^*, \dots, x_n^*)$ il punto stazionario di f , allora esistono m moltiplicatori di Lagrange $\lambda^* = (\lambda_1^*, \dots, \lambda_m^*)$ tali che nel punto (x^*, λ^*) il gradiente della funzione Lagrangiana è nullo ovvero:

$$\frac{\partial L(x^*, \lambda^*)}{\partial x_1} = 0 \text{ con } i = 1, \dots, n$$

$$\frac{\partial L(x^*, \lambda^*)}{\partial \lambda_i} = 0 \text{ con } i = 1, \dots, m$$

I punti che annullano il gradiente potrebbero essere punti di **massimo** o di **minimo**.

- Se la funzione f è **convessa** allora i punti stazionari sono punti di **minimo**
- Se la funzione f è **concava** allora i punti stazionari sono punti di **massimo**

Condizioni del secondo ordine

Come nel caso dell'ottimizzazione non vincolata, anche in questo caso ci sono delle condizioni sufficienti per garantire che i punti stazionari della Lagrangiana siano punti di massimo/minimo della funzione f .

Considero la matrice Hessiana della funzione Lagrangiana ristretta alle variabili $x_1, \dots, x_n$

- Condizione sufficiente affinché x^* sia un punto di **minimo** è che $y^T \cdot H_L(x^*, \lambda^*) \cdot y > 0$
- Condizione sufficiente affinché x^* sia un punto di **massimo** è che $y^T \cdot H_L(x^*, \lambda^*) \cdot y < 0$
- Condizione sufficiente affinché x^* sia un punto di **minimo** è che $y^T \cdot H_L(x^*, \lambda^*) \cdot y \geq 0$
- Condizione sufficiente affinché x^* sia un punto di **massimo** è che $y^T \cdot H_L(x^*, \lambda^*) \cdot y \leq 0$

Procedura generale

1. Si cercano i punti stazionari della lagrangiana per ottenere i possibili candidati ad essere punti di massimo e di minimo.
2. Si utilizzano le condizioni del secondo ordine per eliminare i punti stazionari che sicuramente non sono né di minimo né di massimo (i punti sella).
3. Per i punti rimanenti:
 - a. Se $y^T \cdot H_L(x^*) \cdot y > 0$ oppure $y^T \cdot H_L(x^*) \cdot y < 0$ allora è possibile classificarlo come punto di minimo o massimo.
 - b. Se $y^T \cdot H_L(x^*) \cdot y \geq 0$ oppure $y^T \cdot H_L(x^*) \cdot y \leq 0$ allora non è possibile sapere se tale punto è di minimo o di massimo.

Condizioni di Karush-Kuhn-Tucker:

Le condizioni di Karush-Kuhn-Tucker rappresentano una generalizzazione del metodo dei moltiplicatori di Lagrange applicato a problemi in cui siano presenti anche dei vincoli di disuguaglianza.

Considero un problema di programmazione non lineare vincolata

$$\text{opt} f(x)$$

Soggetto ai seguenti vincoli:

$$g_i(x) = 0 \text{ con } i = 1, \dots, m \text{ vincoli di uguaglianza}$$

$$h_j(x) \leq 0 \text{ con } j = 1, \dots, p \text{ vincoli di disuguaglianza}$$

Sia $x^* = (x_1^*, \dots, x_n^*)$ un punto di ottimo di f , allora $h_j(x^*)$ può essere attivo ($h_j(x^*) = 0$) o inattivo ($h_j(x^*) < 0$). Indico con $I(x^*)$ l'insieme degli indici dei vincoli attivi.

Sia $x^* = (x_1^*, \dots, x_n^*)$ il punto di ottimo di f , allora esistono m moltiplicatori $\lambda^* = (\lambda_1^*, \dots, \lambda_m^*)$ e p moltiplicatori $\mu^* = (\mu_1^*, \dots, \mu_p^*)$ tali che valgono le seguenti condizioni

Condizione di stazionarietà

$$\nabla f(x^*, \lambda^*, \mu^*) = \sum_{i=1}^m \lambda_i^* \cdot \nabla g_i(x^*) - \sum_{j=1}^p \mu_j^* \cdot \nabla h_j(x^*) = 0 \text{ (per problemi di **max**)}$$

$$\nabla f(x^*, \lambda^*, \mu^*) = \sum_{i=1}^m \lambda_i^* \cdot \nabla g_i(x^*) + \sum_{j=1}^p \mu_j^* \cdot \nabla h_j(x^*) = 0 \text{ (per problemi di **min**)}$$

Ammissibilità primale

$$g_i(x^*) = 0 \quad \forall i = 1, \dots, m$$

$$h_j(x^*) \leq 0 \quad \forall j = 1, \dots, p$$

Ammissibilità duale

$$\mu_j^* \geq 0 \quad \forall j = 1, \dots, p$$

Condizioni di complementarità

$$\mu_j^* \cdot h_j(x^*) = 0 \quad \forall j = 1, \dots, p$$

L'ammissibilità del duale e le condizioni di complementarità implicano che, nel caso di vincoli di disuguaglianza, si ottiene:

- Se $h_j(x^*) < 0$ (vincolo non attivo) allora $\mu_j^* = 0$
- Se $h_j(x^*) = 0$ (vincolo attivo) allora $\mu_j^* \geq 0$

Condizioni del secondo ordine

Anche per le condizioni di Karush-Kuhn-Tucker ci sono delle condizioni sufficienti per garantire che i punti stazionari della lagrangiana siano punti di massimo/minimo della funzione f .

Considero l'insieme dei vettori $y \in \mathbb{R}^n$ tali che:

$$J(x^*) \cdot y = 0$$

Dove $J(x^*)$ è una matrice di dimensione $|I(x^*)| \times n$ contenente tutti i gradienti dei vincoli attivi, ovvero:

- Vincoli di uguaglianza (attivi per definizione)
- Vincoli di disuguaglianza attivi

Considero la matrice Hessiana della funzione Lagrangiana ristretta alle variabili iniziali $x_1, \dots, x_n$

- Condizione sufficiente affinché x^* sia un punto di **minimo** è che $y^T \cdot H_L(x^*, \lambda^*, \mu^*) \cdot y > 0$
- Condizione sufficiente affinché x^* sia un punto di **massimo** è che $y^T \cdot H_L(x^*, \lambda^*, \mu^*) \cdot y < 0$
- Condizione sufficiente affinché x^* sia un punto di **minimo** è che $y^T \cdot H_L(x^*, \lambda^*, \mu^*) \cdot y \geq 0$
- Condizione sufficiente affinché x^* sia un punto di **massimo** è che $y^T \cdot H_L(x^*, \lambda^*, \mu^*) \cdot y \leq 0$

Tips and tricks KKT:

- Per verificare che un punto candidato (massimo/minimo) sia effettivamente un **punto stazionario** è sufficiente vedere se tale punto **annulla** il **gradiente** della funzione obiettivo.

- Per trovare i punti di massimo e minimo **globali**, se la regione ammissibile della funzione è limitata allora basta sostituire nella funzione i candidati punti di (minimo/massimo) e verificare quale punto ritorna il valore minore se si sta cercando un minimo globale, viceversa per un massimo globale.